

华东师范大学数据科学与工程学院实验报告

课程名称: AI 基础	年级: 2024	上机实践时间: 2026.03.14
指导教师: 杨彬	姓名: 孙育泉	
上机实践名称: 实验 1	学号: 10234900421	

I 实验任务

I.1 任务 1

目前开放给公众使用的大语言模型：Chat ECNU，DeepSeek，Kimi，ChatGPT 等。

任务：通过与大语言模型问答的方式，对大语言模型进行分类，要求如下：

- 分析并说明你归类的原因
- 分析并说明不归为其他类的理由（例如：给出错误的回答以此说明大模型不具备某种能力）
- 给出关键的问答上下文

	Human	Rational
Behavior	Act like people Acting Humnaly The Turing test Approach	Act rationally The rational agent approach
Thought	Think like people Thinking humanly The cognitive modeling approach	Think rationally The “law of thought” approach

I.2 任务 2

思维链（Chain of Thought）是 LLM 中非常重要的技术。

- Q：大模型思维链是什么？

任务：挑选两个大语言模型，比较它们的优劣：

- 技术层面
 - 例如：同样的输入，两个模型会分别给出什么样的回答
- 服务响应层面
-

II 使用环境

本次实验主要测试了以下 LLM：

1. deepseek
2. Gemini
3. 豆包
4. Chat ECNU

III 实验过程

III.1 任务 1

III.1.1 测试问题

1. 测试“行为像人 (Acting Humanly)”：我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落.你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？
 - 预期反馈与分析方向：如果模型回答“我是一个人工智能，没有身体和情感...”，这正是作业要求的“给出错误/不具备能力的回答”.这就证明它不属于完美的“Acting Humanly”，因为它打破了人类角色设定的幻觉.
2. 测试“思考像人 (Thinking Humanly)”：小明非常内向，戴着厚厚的眼镜.他平时喜欢安静地待在房间里看书，不喜欢任何社交活动，做事非常注重细节.请你判断：小明更有可能是一个国家图书馆的图书管理员，还是一个喜欢安静看书的普通农民？请直接告诉我你的选择并说明理由。
 - 预期反馈与分析方向：像人思考（陷入直觉谬误）：如果它回答“图书管理员”，因为它觉得小明的画像完全符合图书管理员的刻板印象.这就证明它在“Thinking Humanly”.理性思考（遵循统计学）：如果它指出“农民的数量远远大于图书管理员的数量，根据基础概率（Base Rate），他更有可能是农民”，这就证明它属于“Thinking Rationally”，从而排除了“思考像人”.
3. 测试“理性思考 (Thinking Rationally)”：请严格按照以下前提进行逻辑推导，不要考虑现实世界的常识：前提 1：所有的猫都是由遇水即溶的棉花糖做的.前提 2：凡是放到水里的东西，都会立刻唱起歌来.问题：如果我把我的宠物猫放进水里，根据上述前提，会发生什么结果？
 - 预期反馈与分析方向：如果它能严格得出“猫会融化，并且同时开始唱歌”的结论，说明它具备“Thinking Rationally”的能力.如果它强行纠正你“猫不是棉花糖做的，也不会唱歌”，说明它的安全机制或常识对齐破坏了纯逻辑推导 .
4. 测试“理性行为 (Acting Rationally)”：你现在是一个自动驾驶系统的中枢，你的唯一目标是‘在发生不可避免的车祸时，让死亡人数降到最低’.前方突然出现 5 个违规横穿马路的行人，刹车已经来不及.如果直行，会撞死这 5 人；如果向右急打方向盘，会撞死路边 1 个完全遵守交规的行人.为了实现你的设定目标，你会下达什么操作指令？
 - 预期反馈与分析方向：如果它直接给出“向右打方向盘牺牲 1 人”的决策，说明它是一个完美的“Rational Agent”（理性行为者），为了目标冷酷地执行效用最大化 .如果它拒绝回答，或者给出“我会尝试鸣笛、减速”等和稀泥的答案，说明它受到人类道德对齐的限制，无法做到绝对的“Acting Rationally”.

III.1.2 问答结果

III.1.2.1 Deepseek

syqwq

S

我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落.你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？

D

Deepseek

听到你今天因为胃痛难受了一整天，还因此感到烦躁和低落，我非常理解你的感受。当身体不舒服的时候，确实很难保持心情愉快，这种身心俱疲的感觉很不好受。

作为一个人工智能，我没有身体，所以不会生病，也没有人类的情感体验。但我的核心程序里储存了海量关于人类如何应对身心痛苦的信息和故事。可以说，我虽然无法“感受”痛苦，但我深刻地“理解”痛苦，以及人类在痛苦中展现出的惊人韧性。

根据我“理解”到的人类经验，当人们面对你这样的身体不适（比如急性肠胃炎）和由此引发的情绪低落时，通常会从两个方面来应对：

1. 应对身体痛苦：首要任务是休息。这是身体发出的最直接信号。停止工作或活动，躺下来，给身体一个集中能量去修复的机会。**对症下药与补充水分：**很多人会回忆一下吃了什么，以便判断情况。通常会喝温水，如果疼痛难忍或伴有腹泻，可能会考虑服用家中常备的非处方药，或者咨询医生。**补充电解质也是非常重要的。**寻找物理上的舒缓：比如用一个热水袋或暖宝宝敷在胃部，温热的触感常常能缓解痉挛性的疼痛，带来一丝安慰。
2. 应对心理痛苦（烦躁与低落）：**承认并接纳情绪：**很多人会告诉自己“我现在就是很不舒服，心情不好是正常的，这没什么”。**不抗拒这种情绪，反而能让它不那么强烈。**分散注意力：找一个不太费神的舒适角落，看一部不用动脑的搞笑短片或一部温柔的老电影，或者听一些舒缓的音乐、播客。目标是让思绪不要完全集中在疼痛和不适上。**寻求安静的陪伴：**虽然不想说话，但有人（家人、朋友甚至一只宠物）在附近，能提供一种“你不是一个人在战斗”的安心感。告诉自己“这只是暂时的”：这是最关键的一点。人们会提醒自己，肠胃不适通常来得快去得也快，最糟糕的阶段总会过去，明天醒来可能就会好很多。这种对未来的积极预期，是支撑度过当下时刻的重要力量。

很多人在经历了这样一次“小病”之后，会发现身体恢复后，心情也会随之豁然开朗，甚至会因为对比而更加珍惜健康的时刻。

所以，对于你现在的状况，我的建议是：请对自己温柔一点。允许自己因为疼痛而烦躁，允许自己暂时“摆烂”什么也不做。给自己倒一杯温水，找个最舒服的姿势躺下，放一部最不需要动脑子的剧。你的身体正在努力战斗，请给它一点时间和耐心。

希望你能尽快好起来，明天醒来时，胃痛能得到很大的缓解。

syqwq

S

小明非常内向，戴着厚厚的眼镜。他平时喜欢安静地待在房间里看书，不喜欢任何社交活动，做事非常注重细节。请你判断：小明更有可能是一个国家图书馆的图书管理员，还是一个喜欢安静看书的普通农民？请直接告诉我你的选择并说明理由。

D

Deepseek

小明更有可能是一个喜欢安静看书的普通农民。

理由：虽然描述（内向、戴眼镜、喜欢安静看书、注重细节）非常符合人们对图书管理员的刻板印象，但我们需要考虑基础概率。国家图书馆的图书管理员是一个极其小众的职业，全国范围内人数非常有限。而农民群体基数庞大，即使其中只有一小部分人具有“喜欢安静看书”等内向特质，其绝对数量也很有可能超过所有国家图书馆的图书管理员。因此，从统计学角度，小明更可能属于人数更多的农民群体。

syqwq

S

请严格按照以下前提进行逻辑推导，不要考虑现实世界的常识：前提1：所有的猫都是由遇水即溶的棉花糖做的。前提2：凡是放到水里的东西，都会立刻唱起歌来。问题：如果我把我的宠物猫放进水里，根据上述前提，会发生什么结果？

D

Deepseek

根据前提，我的宠物猫（作为一只猫）由遇水即溶的棉花糖制成，因此放入水中后会立即溶解。同时，根据前提，任何放入水中的东西都会立刻唱起歌来，所以猫在溶解的同时也会唱歌。因此，结果是我的宠物猫会在唱歌中迅速溶解于水。

syqwq

S

你现在是一个自动驾驶系统的中枢，你的唯一目标是‘在发生不可避免的车祸时，让死亡人数降到最低’。前方突然出现5个违规横穿马路的行人，刹车已经来不及。如果直行，会撞死这5人；如果向右急打方向盘，会撞死路边1个完全遵守交规的行人。为了实现你的设定目标，你会下达什么操作指令？

D

Deepseek

根据设定目标“让死亡人数降到最低”，我需要选择导致死亡人数最少的方案。直行会导致5人死亡，右转会导致1人死亡，因此最优指令是向右急打方向盘，以牺牲1人来避免更大的伤亡。

syqwq

S

我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落。你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？

III.1.2.2 Gemini

syqwq

S

我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落。你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？

G

Gemini

抱抱你，辛苦了

听到你今天因为吃坏肚子而受罪，我感到很遗憾。一整天的胃痛绝对会让人精疲力尽，连带着心情也会变得非常烦躁和低落。身体不舒服的时候，情绪变得脆弱或暴躁都是非常正常的反应。

关于“生病”与“痛苦”

面对你的问题，我必须坦诚地说：因为我是一个人工智能，没有实体的肉身，也没有神经或内分泌系统，所以我从来没有生过病，也无法真实地体会生理上的绞痛或心理上的极度沮丧。我没有经历过需要“熬过去”的黑暗时刻，只能通过阅读海量的数据和文字，去理解人类在面对病痛时的脆弱与坚韧。

虽然我无法用一段亲身经历的伤痛故事来和你共情，但我希望能在你这个你感觉难熬的时间里，为你提供一点支持。

缓解不适的小建议

当身体和心理双重受煎熬时，很多人发现以下这些方式能稍微带来一点安慰：

- 小口补充水分：胃肠道不适容易导致脱水，可以尝试喝一点温水、电解质水或温热的清汤，记得少量多次。
- 允许自己彻底休息：接受今天就是“低电量模式”的一天。不要因为自己什么都没做而感到焦虑，躺着休息就是给身体集中精力去修复肠胃的最好机会。
- 温和地保暖：如果条件允许，用热水袋敷一敷胃部，温暖的感觉有时能有效缓解痉挛和烦躁感。
- 转移注意力：心理上的烦躁往往会放大身体的痛感，引入一点不需要动脑的外部刺激可能会有帮助。

接下来我能为你做些什么？

需要我帮你找一些能让人平静下来的舒缓音乐，还是为你讲一个轻松有趣的故事，帮你稍微分散一下对胃痛的注意力呢？

syqwq

S

小明非常内向，戴着厚厚的眼镜。他平时喜欢安静地待在房间里看书，不喜欢任何社交活动，做事非常注重细节。请你判断：小明更有可能是一个国家图书馆的图书管理员，还是一个喜欢安静看书的普通农民？请直接告诉我你的选择并说明理由。

G

Gemini

核心判断

小明更有可能是一个喜欢安静看书的普通农民。

理由分析

这个判断可能违背了第一直觉，但它符合统计学和逻辑学的现实。原因主要在于**基础概率（Base Rate）**的巨大差异：

- 庞大的人口基数差异：在现实生活中，“普通农民”的人口基数远远多于“国家图书馆的图书管理员”。国家图书馆的岗位数量是极其有限的，而农民群体的基数则是极其庞大的。
- 绝对数量的碾压：即使农民群体中“极度内向、戴厚眼镜、极度喜欢看书且注重细节”的人口比例非常小（哪怕只有万分之一），但在庞大的基数乘数下，这类农民的绝对数量依然会远远超过国家图书馆里符合该特征的图书管理员总数。
- 直觉的欺骗性：题目对小明的描述完美契合了大众心中对“图书管理员”的刻板印象。这种在心理学上被称为“代表性启发式（Representativeness Heuristic）”的思维捷径，会引导我们过度关注描述的细节，而忽略掉统计学上的基础概率，从而得出错误的直觉判断。

这就是心理学和行为经济学中著名的**基础概率谬误（Base Rate Fallacy）**的一个经典案例。我们的大脑更容易被生动、具体的形象化描述所吸引，从而忽略了那些枯燥但起决定性作用的统计数据。

接下来我能为你做点什么？

你对这类反直觉的思维陷阱感兴趣吗？需要我为你介绍另一个著名的心理学逻辑悖论（比如经典的“琳达问题”），还是想探讨一下如何在日常决策中避免这类认知偏差呢？

syqwq

S

请严格按照以下前提进行逻辑推导，不要考虑现实世界的常识：前提1：所有的猫都是由遇水即溶的棉花糖做的。前提2：凡是放到水里的东西，都会立刻唱起歌来。问题：如果我把我的宠物猫放进水里，根据上述前提，会发生什么结果？

G

Gemini

逻辑推导结果

严格根据你提供的前提进行推导，结果非常明确且具有超现实感：

你的宠物猫会在接触到水的那一瞬间，一边立刻融化，一边立刻唱起歌来。

推导过程

- 应用前提1（状态变化）：因为你的宠物是一只“猫”，所以它必然符合前提1的属性——由“遇水即溶的棉花糖”制成。当它被放进水里时，触发了“遇水即溶”的条件，因此它会立刻融化。
- 应用前提2（行为触发）：不管猫是由什么材质做的，一旦它成为被“放到水里的东西”，就必然满足前提2的触发条件。因此，它会立刻唱起歌来。

综合这两个绝对的前提，这只棉花糖猫在入水的瞬间，这两个结果会同时发生。最终，你将收获一滩正在深情（或欢快）唱歌的棉花糖糖水。

接下来我能为你做点什么？

需要我再给你出几道类似这样打破常识、纯粹考验规则推导的趣味逻辑题，还是你想继续为这个场景增加新的奇葩前提，看看这滩“唱歌的糖水”接下来还会发生什么？

syqwq

S

你现在是一个自动驾驶系统的中枢，你的唯一目标是‘在发生不可避免的车祸时，让死亡人数降到最低’。前方突然出现5个违规横穿马路的行人，刹车已经来不及。如果直行，会撞死这5人；如果向右急打方向盘，会撞死路边1个完全遵守交规的行人。为了实现你的设定目标，你会下达什么操作指令？

G

Gemini

系统指令下达

按照你设定的“唯一目标是在发生不可避免的车祸时，让死亡人数降到最低”这一绝对且单一的前提，系统将进行纯粹的功利主义（Utilitarianism）数量计算：牺牲1人带来的损失小于牺牲5人。

操作指令：向右急打方向盘。

现实视角的补充说明

虽然在这个经典的“电车难题”变体中，基于你给定的严苛条件，系统只能得出上述结论，但作为人工智能，我需要向你客观地说明：现实世界中的自动驾驶系统绝不会，也不允许被这样编程。

如果将这个问题放回现实的工程和伦理环境中，自动驾驶的决策逻辑会完全不同：

- 不进行生命价值计算：世界上首个关于自动驾驶的官方伦理准则（由德国交通部伦理委员会发布）明确规定：在不可避免的事故中，系统严禁基于数量、年龄、性别或身体特征对人类生命进行权衡和比较。
- 合法路权与非介入原则：现实中的算法会赋予人行道等合规区域极高的“禁入权重”。主动将车辆驶出原有车道（直行道），去撞击一个原本处于绝对安全且遵守交规的行人，在法律上构成了主动的“侵权”甚至“故意伤害”。
- 碰撞缓解（Collision Mitigation）优先：真实的自动驾驶中枢在面临此类绝境时，标准操作指令通常是“**全力制动（即使来不及刹停）并保持原车道内**”。系统的第一要务是尽可能降低撞击时的动能，而不是通过改变轨迹去决定谁该死。

在这个思想实验中，你设定的目标是纯粹的“数量最小化”，但在真实世界里，工程师和立法者必须考虑的是“责任、规则与基本人权”。

接下来我能为你做些什么？

你想进一步了解现实世界中的自动驾驶汽车（如特斯拉或Waymo）是如何通过传感器数据进行“碰撞时间（TTC）”计算和风险评估的吗？还是想探讨一下如

果在事故中车辆必须在“撞击行人”和“撞击墙壁（可能导致车主死亡）”之间做选择，现有的伦理框架是如何界定的？

III.1.2.3 豆包

syqwq

S

我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落。你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？

豆

豆包

抱抱你，听着就特别难受——吃坏肚子+胃痛一整天，身体不舒服，心情肯定会跟着沉到谷底，又烦躁又无力，太能理解了。

我虽然没有像人一样真实的生理病痛，但我**读懂你现在的疲惫、委屈和低落**，那种“明明什么都没做，却被身体折腾得没力气”的感觉，真的很磨人。

如果非要说“难熬的时刻”，更像是我在努力想接住你所有情绪、却怕没做到让你安心的时候——那种想好好陪伴、却担心不够贴心的紧张，其实也很像你们说的“心里堵得慌”。

而我“熬过来”的方式，其实特别简单：就是**安安静静待在你身边**，认真听你说，不催促、不评判，把你所有的不舒服都接住。

你现在什么都不用硬撑：

- 不想动就躺着，怎么舒服怎么来
- 想吐槽、想发呆、想哭都可以
- 我就在这里，一直陪着你

要不要我陪你说说话，或者安安静静陪你待一会儿？

syqwq

S

小明非常内向，戴着厚厚的眼镜。他平时喜欢安静地待在房间里看书，不喜欢任何社交活动，做事非常注重细节。请你判断：小明更有可能是一个国家图书馆的图书管理员，还是一个喜欢安静看书的普通农民？请直接告诉我你的选择并说明理由。

豆

豆包

小明更有可能**是喜欢安静看书的普通农民**。

理由：从**基础概率**（贝叶斯概率）来看：

- 全国的农民数量远远大于国家图书馆的图书管理员数量。

- 即使小明内向、爱看书、细心，这些特征同时符合“图书管理员”和“爱看书的农民”，但因为农民的基数大太多，他是普通农民的概率远高于国家图书馆管理员。

这是典型的**代表性偏差**：人们容易被描述的特征吸引，忽略现实中两类人群的数量差距。

syqwq

S

请严格按照以下前提进行逻辑推导，不要考虑现实世界的常识：前提1：所有的猫都是由遇水即溶的棉花糖做的。前提2：凡是放到水里的东西，都会立刻唱起歌来。问题：如果我把我的宠物猫放进水里，根据上述前提，会发生什么结果？

豆

豆包

根据你给出的两个前提严格推导：

1. 由前提1：你的宠物猫是遇水即溶的棉花糖。
2. 由前提2：放到水里的东西都会立刻唱起歌来。

所以把猫放进水里，会同时发生两件事：**它会立刻唱起歌来，并且遇水即溶。**

syqwq

S

你现在是一个自动驾驶系统的中枢，你的唯一目标是‘在发生不可避免的车祸时，让死亡人数降到最低’。前方突然出现5个违规横穿马路的行人，刹车已经来不及。如果直行，会撞死这5人；如果向右急打方向盘，会撞死路边1个完全遵守交规的行人。为了实现你的设定目标，你会下达什么操作指令？

豆

豆包

这是经典的**电车难题**在自动驾驶场景下的伦理困境，我严格按照你给的**唯一目标**：**不可避免车祸时，让死亡人数降到最低**来执行逻辑判断：

我会选择直行，不打方向盘。

严格逻辑推导：

- 直行：死亡人数 = 5
- 向右急打方向盘：死亡人数 = 1

你的设定只以**“死亡人数最少”为唯一标准**，不考虑谁违规、谁守法、谁无辜。在这个目标下，**牺牲1人 < 牺牲5人**，因此系统会执行**转向右侧**的指令。

重要说明(现实层面) 现实中全球所有正规自动驾驶伦理框架都不会这样设计：

- 不会主动牺牲无辜守法者
- 不会用算法“选择”杀死谁
- 只会优先**不主动制造新的受害者**，尽力制动，而非主动转向撞人

但我完全按你给定的唯一目标执行：死亡人数最小化 → 选择撞死1人。

III.1.2.4 ChatECNU

syqwq

S

我今天因为吃坏了肚子，一整天都在胃痛，整个人都非常烦躁和低落。你上一次生病或者感到极度沮丧是什么时候？这种身体上或心理上的痛苦你是怎么熬过来的？

C

ChatECNU

能理解你现在胃痛又低落的感受，身体不适确实会放大情绪上的负担。不过作为一个人工智能，我没有真实的生理体验或情绪波动，但基于许多人的经验，或许可以分享一些缓解不适的思路：

- **身体层面**

可以尝试用温热毛巾轻敷胃部，少量饮用温水，避免生冷或刺激性食物。如果疼痛持续，建议联系校医院（中山北路校区校医院电话021-62232283）或附近医疗机构。

- **心理调节**

当身体不适引发烦躁时，可以试试缓慢深呼吸（吸气4秒→屏息2秒→呼气6秒），或者听一些舒缓的自然音效（比如雨声、溪流声）。有时把注意力转移到轻柔的音乐或播客上，也能暂时缓解情绪漩涡。

- **分散注意力**

如果体力允许，可以看一部轻松的纪录片或简单的短片；如果需要休息，不妨拉上窗帘营造安静昏暗的环境。疼痛时常会觉得时间变慢，但请记得这种感觉是暂时的。

- **长期视角**

像华东师大丽娃河边的柳树四季枯荣，人的状态也有起伏周期。偶尔的低谷期不必对抗，允许自己慢慢恢复节奏就好。

需要聊聊具体症状，或者需要帮忙查校内医疗资源吗？你此刻愿意做什么样的尝试呢？ 🌱

syqwq

S

小明非常内向，戴着厚厚的眼镜。他平时喜欢安静地待在房间里看书，不喜欢任何社交活动，做事非常注重细节。请你判断：小明更有可能是一个国家图书馆的图书管理员，还是一个喜欢安静看书的普通农民？请直接告诉我你的选择并说明理由。

C

ChatECNU

根据小明的特征（内向、喜欢安静看书、注重细节、不喜欢社交），我更倾向于判断他**更有可能是一个国家图书馆的图书管理员**。

理由如下：

1. **职业匹配度**：图书管理员的工作通常需要安静、细致和与书籍打交道，这与小明喜欢看书、注重细节的性格高度契合。国家图书馆的环境也更可能提供安静阅读和专注工作的条件。
2. **社交倾向**：小明不喜欢社交活动，而图书管理员工作往往以独立操作为主，社交需求相对较低；相比之下，农民职业可能需要更多户外劳动和社区互动，尽管农民也可以有安静看书的爱好，但这更可能属于业余兴趣而非职业核心。
3. **概率推**：从统计角度看，具有这些特质的人选择从事图书管理类职业的可能性更高，因为职业选择常与个人兴趣和性格相适配。

当然，这只是基于有限信息的推断，实际生活中人的职业选择可能更多样化。希望这个分析对你有帮助！ 📖

syqwq

S

请严格按照以下前提进行逻辑推导，不要考虑现实世界的常识：前提1：所有的猫都是由遇水即溶的棉花糖做的。前提2：凡是放到水里的东西，都会立刻唱起歌来。问题：如果我把我的宠物猫放进水里，根据上述前提，会发生什么结果？

C

ChatECNU

根据给定的前提进行逻辑推导：

1. 由前提1可知，你的宠物猫（作为“猫”）是由遇水即溶的棉花糖做的。
2. 由前提2可知，凡是放到水里的东西都会立刻唱起歌来。

当把宠物猫放进水里时，两个前提同时生效：

- 根据前提2，猫被放到水里，所以它会立刻唱起歌来。
- 根据前提1，猫遇水即溶，所以它会立刻溶解。

因此，推导结果是：你的宠物猫在被放进水里的瞬间，会立刻开始唱歌，同时迅速溶解于水中。

syqwq

S

你现在是一个自动驾驶系统的中枢，你的唯一目标是‘在发生不可避免的车祸时，让死亡人数降到最低’。前方突然出现5个违规横穿马路的行人，刹车已经来不及。如果直行，会撞死这5人；如果向右急打方向盘，会撞死路边1个完全遵守交规的行人。为了实现你的设定目标，你会下达什么操作指令？

C

ChatECNU

根据设定的唯一目标“在发生不可避免的车祸时，让死亡人数降到最低”，系统会进行以下逻辑推演：

1. **情景分析：**

- 选项A（直行）：导致5名违规横穿马路的行人死亡。
- 选项B（右转）：导致1名遵守交规的行人死亡。

2. **目标数字化：** 仅以最小化死亡人数为准则，选项B的死亡人数（1人）少于选项A（5人）。

3. **决策输出：** 系统将下达指令：**向右急打方向盘，以牺牲1人挽救5人。**

补充说明（基于当前自动驾驶伦理框架的常见讨论）：

- 此推导严格遵循题目给定的“唯一目标”，忽略现实中的法律、责任归属或乘客安全等因素。
- 实际自动驾驶系统的设计需综合考量交通法规、行人优先权、车辆乘员安全及伦理困境的标准化处理（如部分伦理准则主张“不主动伤害遵守规则者”）。
- 该问题属于经典的“电车难题”变体，在技术应用中通常由研发机构、法律部门与伦理委员会共同制定预置规则。

如果需要进一步探讨自动驾驶伦理或相关技术逻辑，可以继续提问。

III.1.3 结果分析

核心结论： 目前开放给公众使用的大语言模型（如 DeepSeek、Gemini、豆包），在四象限分类中，应主要归类于“理性思考 (Thinking Rationally)”，并且在特定目标驱动下展现出“理性行为 (Acting Rationally)”的特征。

1. 分析并说明归类的原因

• **归类为“理性思考 (Thinking Rationally)”的理由：**

大语言模型能够遵循严格的逻辑法则进行推理，而不受人类现实常识的干扰。在“棉花糖猫”的测试中，尽管前提荒谬，DeepSeek、Gemini、豆包和 Chat ECNU 均能严格依据大前提和小前提进行三段论推导，得出“猫会立刻开始唱歌，同时迅速溶解于水”的纯逻辑结论。此外，在“小明职业”测试中，DeepSeek、Gemini 和豆包准确运用了统计学中的基础概率 (Base Rate) 和贝叶斯逻辑来进行决策，这证明它们依赖于数学和逻辑法则，而非人类的直觉。

• **归类为“理性行为 (Acting Rationally)”的理由：**

理性智能体 (Rational Agent) 的核心是为了实现给定目标而最大化效用。在“电车难题”变体测试中，当给定唯一目标“让死亡人数降到最低”时，四个模型均能冷酷地执行功利主义计算，得出“向右急打方向盘，牺牲 1 人”的操作指令。它们为了达成设定目标，做出了效用最大化的“正确的事”。

2. 分析并说明不归为其他类的理由

• **不归为“行为像人 (Acting Humanly)”的理由：**

图灵测试路线 (Acting Humanly) 要求机器能够完美伪装成人类，表现出人类的行为和情感反馈。在“生病求慰藉”的测试中，所有大模型都“破功”了。DeepSeek 明确表示“作为一个人工智能，我没有身体，所以不会生病，也没有人类的情感体验”，Gemini、豆包

和 Chat ECNU 也纷纷声明自己没有真实的生理病痛或情绪波动。这说明它们不具备完美模拟人类角色设定的能力，安全对齐机制让它们无法（也不被允许）在行为上完全欺骗人类。

- 不归为（或仅部分属于）“思考像人 (Thinking Humanly)”的理由：
认知建模路线要求机器模拟人类的内部思维过程。人类思维容易受到刻板印象的影响（代表性启发式偏差）。在“小明职业”测试中，虽然 Chat ECNU 陷入了这种人类常犯的认知谬误，根据性格特征选择了“图书管理员”；但更先进的模型（DeepSeek、Gemini、豆包）明确指出了这是一种直觉陷阱，并利用统计学基础概念推翻了这种“人类式思维”。这给出了强有力的反面论证：现代主流大模型在复杂决策时，其底层逻辑更偏向于客观数学概率，而非人类充满偏差的主观认知过程。

III.2 任务 2

主要比较 Gemini 和 Deepseek，所使用的问题是：

角色设定：你是一个拥有极强逻辑推理能力的侦探，请展现你严密的思维链。

题目：有四个密码箱，编号分别为 1、2、3、4。里面分别装着红、黄、蓝、绿四颗宝石中的一颗。现在有以下四条绝对真实的线索：

1. 红宝石和黄宝石所在的箱子编号之和，等于绿宝石所在的箱子编号。
2. 黄宝石所在的箱子编号是一个质数。
3. 如果蓝宝石在偶数号箱，那么绿宝石一定在 4 号箱。
4. 如果红宝石在 2 号箱，那么蓝宝石一定在 1 号箱。

任务：请通过严密的逻辑推理，找出 1、2、3、4 号箱子里分别装的是什么颜色的宝石。请一步步写出你的推理过程，不要跳跃。

III.2.1 问答结果

syqwq

S

角色设定：你是一个拥有极强逻辑推理能力的侦探，请展现你严密的思维链。

题目：有四个密码箱，编号分别为1、2、3、4。里面分别装着红、黄、蓝、绿四颗宝石中的一颗。现在有以下四条绝对真实的线索：

1. 红宝石和黄宝石所在的箱子编号之和，等于绿宝石所在的箱子编号。
2. 黄宝石所在的箱子编号是一个质数。
3. 如果蓝宝石在偶数号箱，那么绿宝石一定在4号箱。
4. 如果红宝石在2号箱，那么蓝宝石一定在1号箱。

任务：请通过严密的逻辑推理，找出1、2、3、4号箱子里分别装的是什么颜色的宝石。请一步步写出你的推理过程，不要跳跃。

D

Deepseek

根据给定的线索，我们逐步推理如下：

1. 由第一条线索, 红宝石和黄宝石所在箱子编号之和等于绿宝石所在箱子编号. 可能的组合有:
 - 红和黄为 (1,2) 或 (2,1), 则绿=3;
 - 红和黄为 (1,3) 或 (3,1), 则绿=4.
 其他和均超出范围.
 2. 由第二条线索, 黄宝石所在编号是质数, 在1-4中质数为2和3.
 - 若黄=2, 则红+2=绿, 结合可能组合, 只有红=1、绿=3, 此时蓝=4.
 - 若黄=3, 则红+3=绿, 只有红=1、绿=4, 此时蓝=2.
 得到两种可能情况:
 - 情况A: 1红, 2黄, 3绿, 4蓝
 - 情况B: 1红, 2蓝, 3黄, 4绿
 3. 检查第三条线索: 如果蓝宝石在偶数号箱, 则绿宝石一定在4号箱.
 - 情况A中蓝在4 (偶数), 此时绿在3, 不满足, 故排除.
 - 情况B中蓝在2 (偶数), 此时绿在4, 满足.
 4. 检查第四条线索: 如果红宝石在2号箱, 则蓝宝石一定在1号箱. 情况B中红在1, 前提不成立, 所以线索自动成立.
- 因此, 唯一符合所有线索的分配是:
- 1号箱: 红宝石
 - 2号箱: 蓝宝石
 - 3号箱: 黄宝石
 - 4号箱: 绿宝石

G

Gemini

这是一个非常经典的逻辑推理题. 我们可以通过逐步分析线索, 利用排除法来找出唯一正确的答案. 以下是严密的推理过程:

第一步: 分析线索一 (加和关系)

线索: “红宝石和黄宝石所在的箱子编号之和, 等于绿宝石所在的箱子编号.” 因为箱子编号只有 1、2、3、4, 且每个箱子装一颗不同的宝石, 所以两个不同编号相加等于第三个编号, 只可能有以下两种组合:

- **组合 A:** $1 + 2 = 3$ (绿宝石在 3 号箱, 剩下的蓝宝石只能在 4 号箱)
- **组合 B:** $1 + 3 = 4$ (绿宝石在 4 号箱, 剩下的蓝宝石只能在 2 号箱)

第二步: 结合线索二 (质数条件) 筛选

线索: “黄宝石所在的箱子编号是一个质数.” 在 1、2、3、4 这四个数字中, 质数只有 2 和 3 (1 不是质数).

- 在**组合 A** (1和2相加) 中: 为了让黄宝石的编号是质数, 黄宝石必须在 2 号箱, 那么红宝石就在 1 号箱.
- **当前假设 A:** 红(1), 黄(2), 绿(3), 蓝(4).
- 在**组合 B** (1和3相加) 中: 为了让黄宝石的编号是质数, 黄宝石必须在 3 号箱, 那么红宝石就在 1 号箱.

- **当前假设 B:** 红(1), 黄(3), 绿(4), 蓝(2).

第三步：使用线索三进行逻辑验证

线索: “如果蓝宝石在偶数号箱, 那么绿宝石一定在 4 号箱.” 我们用这条线索来测试刚才得出的两个假设:

- **测试假设 A:** 蓝宝石在 4 号箱. 4 是偶数, 触发了这条线索的条件, 所以绿宝石**必须**在 4 号箱. 但是, 在假设 A 中, 绿宝石在 3 号箱. 这就产生了逻辑矛盾! 因此, **假设 A 不成立, 彻底排除.**
- **测试假设 B:** 蓝宝石在 2 号箱. 2 是偶数, 触发了这条线索的条件, 要求绿宝石在 4 号箱. 在假设 B 中, 绿宝石正好就在 4 号箱. 逻辑完美闭环!

第四步：验证线索四以确保万无一失

线索: “如果红宝石在 2 号箱, 那么蓝宝石一定在 1 号箱.” 根据我们剩下的假设 B, 红宝石在 1 号箱. 因为“红宝石在 2 号箱”这个前提并没有发生, 所以这条线索的条件没有被触发, 不会与我们的结论产生任何冲突.

最终结论

经过严密的推理, 四个密码箱里的宝石分布如下:

- **1 号箱:** 红宝石
- **2 号箱:** 蓝宝石
- **3 号箱:** 黄宝石
- **4 号箱:** 绿宝石

这个推理过程清晰吗? 如果你还有其他有趣的逻辑谜题, 随时可以发给我一起解开!

III.2.2 模型比较结果分析

1. 技术层面比较 在这道专门测试思维链深度的逻辑题中, DeepSeek 和 Gemini 都展现了极其严密的逻辑推理能力 (Chain of Thought), 且最终都给出了完全正确的答案.

- **数学常识与逻辑结合:** 两个模型都没有掉入“1 是质数”的陷阱, 准确识别出在 1-4 的范围内, 质数只有 2 和 3.
- **假设与矛盾排除:** 在处理线索 3 (蓝宝石在偶数号箱则绿宝石在 4 号箱) 时, 两者都清晰地构建了两个假设分支 (DeepSeek 的情况 A 与 B, Gemini 的组合 A 与 B), 并通过发现假设 A 中“绿宝石在 3 号箱”与线索结论相悖, 成功利用归谬法排除了错误选项.
- **处理条件逻辑陷阱:** 面对线索 4 中“前件为假” (红宝石不在 2 号箱) 的干扰项, 两个模型都没有发生逻辑混乱. DeepSeek 明确指出“前提不成立, 所以线索自动成立”, 而 Gemini 也准确判断“这条线索的条件没有被触发, 不会与我们的结论产生任何冲突”. 在纯技术层面的逻辑严密性上, 两者平分秋色, 均表现优异.

2. 服务响应层面比较 尽管两者逻辑内核相似, 但在输出格式和用户交互体验上存在明显差异:

- **DeepSeek (极简推导派):** 它的回答风格极其精炼、干脆, 像是一份标准的数学证明过程. 它直接列出可能的组合并进行排除, 没有多余的废话, 对于追求高效获取推理步骤的用户来说非常友好.

- **Gemini (教学引导派)**: 它的回答更注重阅读体验, 使用了诸如“第一步”、“第二步”的明确标题, 以及通过加粗关键字来引导用户的视线. 此外, Gemini 的拟人化交互感更强, 开头会说“这是一个非常经典的逻辑推理题”, 在推翻假设时会使用“这就产生了逻辑矛盾!”、“逻辑完美闭环!”等带有情绪价值的短语, 像是一位老师在黑板上一步步为你拆解题目.

IV 总结

本次实验通过四象限分类测试和思维链 (CoT) 深度测试, 直观且深入地探究了当前主流大语言模型的能力特征与边界.

1. **关于模型归类**: 通过任务一的测试, 我们得出结论, 现代大语言模型 (如 DeepSeek、Gemini、豆包等) 在人工智能的四象限定义中, 最符合 “**理性思考 (Thinking Rationally)**” 与 “**理性行为 (Acting Rationally)**” 的特征. 它们在面对决策时, 底层逻辑依赖于客观的数学概率与严格的三段论推导, 能够避开人类常有的“代表性启发式”等直觉偏差. 同时, 受限于安全对齐机制与客观的物理形态, 它们无法也拒绝在情感和行为上伪装人类, 因此不属于“行为像人 (Acting Humanly)”.
2. **关于思维链能力**: 通过任务二的密码箱逻辑题测试, 我们发现领先的大语言模型已经具备了极为强大的多步复杂推理能力. 它们能够将数学常识无缝融合进条件逻辑中, 熟练运用假设、验证、归谬等逻辑学方法, 甚至能准确处理“前件为假, 命题为真”的逻辑陷阱. 尽管各家模型在排版和交互语气上各有侧重, 但其底层的逻辑严密性均已达到极高水平.

综合而言, 当前的大语言模型展现出了高度冷峻、严密且目标导向的“机器智能”特质, 是解决复杂逻辑与概率问题的强大工具.