

基于深度学习的 睡眠状态事件检测

孙育泉 10234900421

目录

- 背景介绍
- 任务分析
- 我的方案
- 实验结果

目录

- 背景介绍
- 任务分析
- 我的方案
- 实验结果


背景介绍



本项目来自 Kaggle 比赛 **Child Mind Institute - Detect Sleep States**。

该任务的目标是根据手环传感器采集到的时间序列数据，自动检测儿童睡眠过程中的两个关键事件：

- ❑ onset 入睡时刻
- ❑ wakeup 醒来时刻



数据主要包括每个时间步的传感器特征，例如：

- ❑ anglez 手腕角度
- ❑ enmo 运动强度
- ❑ timestamp 时间戳
- ❑ series_id 记录序列的编号
- ❑ step 时间序列中的步数

目录

- 背景介绍
- 任务分析
- 我的方案
- 实验结果

任务分析

数据集结构

datasets/

- └─ train_series.parquet 训练用传感器时间序列
- └─ train_events.csv 训练集真实事件标注
- └─ test_series.parquet 测试集传感器时间序列
- └─ sample_submission.csv 提交格式样例


任务分析

数据集结构

datasets/

├─ train_series.parquet 训练用传感器时间序列
└─ ...

series_id	step	timestamp	anglez	enmo
038441c925bb	0	2018-08-14T15:30:00-0400	2.6367	0.0217
038441c925bb	1	2018-08-14T15:30:05-0400	2.6368	0.0215
038441c925bb	2	2018-08-14T15:30:10-0400	2.6370	0.0216



行数: 127,946,340
series 数量: 277
列数: 5
1 step = 5 秒

任务分析 数据集结构

datasets/

└─ train_events.csv 训练集真实事件标注

└─ ...

series_id	night	event	step	timestamp
038441c925bb	1	onset	4992.0	2018-08-14T22:26:00-0400
038441c925bb	1	wakeup	10932.0	2018-08-15T06:41:00-0400
038441c925bb	2	onset	20244.0	2018-08-15T19:37:00-0400
038441c925bb	2	wakeup	27492.0	2018-08-16T05:41:00-0400
038441c925bb	5	onset	NaN	NaN
038441c925bb	5	wakeup	NaN	NaN

总行数: 14,508

series 数量: 277

有效标注行数: 9,585

任务分析 数据集结构

datasets/

├─ test_series.parquet 测试集传感器时间序列
└─ ...

series_id

.....

step

...

timestamp

.....

anglez

.....

enmo

.....

任务分析 数据集结构

datasets/

├ ...

└ sample_submission.csv 提交格式样例

row_id	series_id	step	event	score
0	038441c925bb	100	onset	0.0
1	038441c925bb	105	wakeup	0.0
2	03d92c9f6f8a	80	onset	0.5
3	03d92c9f6f8a	110	wakeup	0.5

任务分析 评价指标

真实事件

$$G = \{g_i\}_{i=1}^N, g_i = (s_i, e_i, t_i), G_e = \{g_i \in G \mid e_i = e\}$$

$$P = \{p_j\}_{j=1}^M, p_j = (\hat{s}_j, \hat{e}_j, \hat{t}_j, c_j), P_e = \{p_j \in P \mid \hat{e}_j = e\}$$

预测事件

$$(\hat{s}_j = s_i) \wedge (\hat{e}_j = e_i) \wedge (|\hat{t}_j - t_i| \leq \tau) \Rightarrow p_j \rightarrow \text{TP}$$

$$c_1 \geq c_2 \geq \dots \geq c_M$$

$\forall g_i \in G, g_i$ can be matched at most once

$$\text{TP}(k) = \sum_{j=1}^k \mathbb{I}(p_j \rightarrow \text{TP}), \text{FP}(k) = \sum_{j=1}^k \mathbb{I}(p_j \rightarrow \text{FP}),$$

$$\text{Precision}(k) = \frac{\text{TP}(k)}{\text{TP}(k) + \text{FP}(k)}, \text{Recall}(k) = \frac{\text{TP}(k)}{|G_e|}$$

$$\begin{aligned} \text{AP}(e, \tau) &= \int_0^1 \text{Prec}_e(r; \tau) \, dr \\ &= \sum_{k=1}^M [\text{Recall}(k) - \text{Recall}(k-1)] \cdot \max_{\tilde{k} \geq k} \text{Precision}(\tilde{k}) \end{aligned}$$


$$\mathcal{E} = \{\text{onset}, \text{wakeup}\}, \mathcal{T} = \{12, 36, 60, \dots, 360\}$$

$$\text{Score} = \frac{1}{|\mathcal{E}| \cdot |\mathcal{T}|} \sum_{e \in \mathcal{E}} \sum_{\tau \in \mathcal{T}} \text{AP}(e, \tau)$$

目录

- 背景介绍
- 任务分析
- 我的方案
- 实验结果

我的方案 流程思路



我的方案

特征工程

差分特征

- d_anglez
- abs_d_anglez
- d_enmo
- abs_d_enmo

窗口特征

- anglez_mean_12
- anglez_std_12
- enmo_mean_60
- enmo_std_60
- anglez_mean_360
- enmo_std_1440

时间特征

- hour_sin
- hour_cos
- minute_sin
- minute_cos
- weekday_sin
- weekday_cos

window_size: 7200 => 10 h

我的方案 标签设计


One-Hot



$$y(t) = \boldsymbol{w}^\top \exp\left(-\frac{(t - t_0)^2}{2\sigma^2}\right)$$



我的方案 模型架构



我的方案

损失函数

$$\mathcal{L}_{\text{CE}} = -[y \log(p) + (1 - y) \log(1 - p)] \quad \text{太多负样本了, 模型会过于保守}$$

$$\mathcal{L}_{\text{Focal}} = -[\alpha y (1 - p)^\gamma \log(p) + (1 - \alpha)(1 - y) p^\gamma \log(1 - p)] \quad \text{关注难样本}$$

$$\mathcal{L} = \mathcal{L}_{\text{event}} + \lambda_1 \mathcal{L}_{\text{sleep}} + \lambda_2 \mathcal{L}_{\text{boundary}}$$

$$\mathcal{L}_{\text{event}} = \mathcal{L}_{\text{onset}} + \mathcal{L}_{\text{wakeup}}$$

$$\mathcal{L}_{\text{sleep}} = \frac{\sum_{b=1}^B \sum_{t=1}^T m_{b,t}^{\text{sl}} \mathcal{L}_{\text{CE}}(\sigma(z_{b,t}^{\text{sl}}), y_{b,t}^{\text{sleep}})}{\max(\sum_{b=1}^B \sum_{t=1}^T m_{b,t}^{\text{sl}}, 1)}, m_{b,t}^{\text{sl}} \in \{0, 1\}$$

$$\mathcal{L}_{\text{boundary}} = \frac{\sum_{b=1}^B \sum_{t=2}^T m_{b,t}^{\text{valid}} \cdot \text{ReLU}(|p_{b,t}^{\text{sl}} - p_{b,t-1}^{\text{sl}}| - \max(p_{b,t}^{\text{on}}, p_{b,t}^{\text{wu}}))}{\max(\sum_{b=1}^B \sum_{t=2}^T m_{b,t}^{\text{valid}}, 1)}, m_{b,t}^{\text{valid}} \in \{0, 1\}$$

我的方案

后处理方法

- 概率平滑
- 峰值检测
- 峰值间距限制
- 置信度 score 的计算
- 阈值过滤
- 每条序列最大事件数限制

$$s_{e(t)} = \alpha \tilde{p}_e(t) + (1 - \alpha) \text{Mass}_e(t) - \beta p_{\text{invalid}}(t)$$

我的方案 改良方法

- Event-focused Sampling
- 损失函数改良
- 后处理调参
- 模型规模实验
- 模型融合实验
- Pair Filter 实验

目录

- 背景介绍
- 任务分析
- 我的方案
- 实验结果

实验结果 实验数据

实验设置	OOF	Local	Private	Public	结论
Small baseline	0.0409		0.411	0.363	验证流程跑通
Medium+ 2-fold	0.0777		0.605	0.534	最佳稳定版本
Large 2-fold	0.0700		0.552	0.484	更大模型未带来提升
Medium+ 3-model ensemble	-		0.597	0.517	简单融合收益有限
Event-focused + focal loss	0.0814		0.597	0.543	本地提升明显
Debug: pair filter	0.0380		-	-	后处理策略不稳定，未提交
Debug: boundary mix	0.0757		-	-	结构改良未显著提升
Debug: fullish lazy windows	0.0559		-	-	实现/内存问题，未提交
Debug: event plus w2	0.0814		-	-	参数搜索实验，未提交

实验结果 反思

- ❑ 模型不是越大越好
- ❑ 本地分数不一定完全代表榜单分数
- ❑ 做不同模型/不同窗口长度的融合

THANK YOU!

